

UNIVERSITÀ DI PISA

Department of Computer Science

Master in Data Science and Business Informatics

Decision Support Systems Laboratory

Professors:
Prof. Anna Monreale
Dott. Cristiano Landi

Student:
Elisa Lucarelli
Riccardo Ranieri
Pietro Gagliardi

Academic Year 2025/26

Contents

1 INTRODUZIONE **2**
1.1 Data understanding 2
1.2 Data cleaning 2
1.3 Song profiling 3
1.4 Data Warehouse Schema 3
1.5 Partizionamento dei dati per le tabelle del Data Warehouse 4
1.6 Data uploading con python 5
1.7 Caricamento dei dati con SSIS (30% del dataset) 5
2 Query analitiche con SSIS **6**
2.1 Assignment 8 6
2.2 Assignment 9 7
2.3 Assignment 10 8
2.4 Assignment 11 9
2.5 Assignment 12 10
2.6 Assignment 13 11
3 Multidimensional Data Analysis **12**
3.1 OLAP Cube 12
3.2 MDX queries 12
3.2.1 Assignment 15 12
3.2.2 Assignment 16 13
3.2.3 Assignment 17 14
3.2.4 Assignment 18 15
3.2.5 Relative popularity index 15
4 Dashboards **17**
4.1 Distribuzione degli stream per luogo di nascita dell'artista e categoria del brano 17
4.2 Lyrics analysis 18
4.3 Evoluzione temporale degli stream e delle categorie musicali 19

1 INTRODUZIONE

In questo report presenteremo le fasi che ci hanno permesso di progettare e implementare un sistema di supporto alle decisioni per una piattaforma musicale. Il progetto prende in esame due dataset: "Tracks" e "Artists". A partire dai dati forniti, vengono svolte diverse attività: analisi preliminare dei dataset, progettazione dello schema del Data Warehouse, creazione e popolamento del Data Warehouse, definizione ed esecuzione di query analitiche tramite SQL Server Integration Services, costruzione di un datacube per supportare analisi multidimensionali mediante query MDX e infine, la realizzazione di dashboard interattivi per rispondere a specifiche esigenze aziendali.

1.1 Data understanding

Nel dataset **Tracks** ogni record descrive una singola canzone e integra sia caratteristiche testuali (titolo, testo, lingua ed eventuale linguaggio esplicito) sia proprietà audio (bpm, loudness, spectral measures, rolloff, flux, rms, flatness, spectral_complexity, pitch). Inoltre contiene dati discografici, ad esempio se la traccia fa parte di un singolo, di un album o di una compilation. Sono presenti anche informazioni temporali, come il giorno, il mese e l'anno in cui la traccia è stata pubblicata. Infine, è disponibile la misura degli stream mensili a un mese dall'uscita, utile per analizzare le performance commerciali dei brani.
A ogni canzone del dataset Tracks corrisponde un artista principale ed eventualmente uno o più artisti secondari. In particolare, l'artista principale è collegato al dataset **Artists** tramite un identificativo. In questo secondo dataset vengono fornite informazioni anagrafiche e geografiche sugli artisti come: nome, genere, data e luogo di nascita, nazionalità, anni di attività e coordinate geografiche. Questi dati permettono di collegare ciascun brano al suo autore principale e di svolgere analisi comparative tra artisti e aree territoriali.

1.2 Data cleaning

Durante la fase di data cleaning sono stati individuati e trattati diversi valori mancanti.
Nel dataset **Artist**, i valori mancanti relativi a *birth_place*, *birth_date* e *active_start* sono stati integrati manualmente sulla base di informazioni esterne, quando disponibili. L'attributo country è stato uniformato assegnando il valore "Italia" a tutti gli artisti, mentre la colonna nationality, ridondante rispetto a country, è stata rimossa. I valori mancanti di province e region sono stati ricavati a partire dal luogo di nascita tramite dizionari di mappatura, mentre latitude e longitude sono stati integrati mediante un servizio di geocodifica. Per gli artisti privi di coordinate geografiche è stato assegnato un valore nullo. È stata inoltre introdotta la variabile *artist_type*. In particolare, per ciascun artista è stata analizzata la stringa descrittiva associata: nel caso in cui il testo contenesse il termine "gruppo", l'artista è stato classificato come *gruppo*; in tutti gli altri casi, inclusa l'assenza della descrizione, l'artista è stato classificato come *solista*. Una volta estratta questa informazione, la colonna *description* è stata rimossa dal dataset per evitare ridondanze. È stata inoltre rimossa la variabile *active_end* perchè non risultava rilevante ai fini delle analisi previste e presentava un'elevata percentuale di valori mancanti, non contribuendo in modo significativo all'analisi che stavamo condicendo.
Nel dataset **Tracks**, i valori mancanti relativi a *year*, *month* e *day* sono stati completati utilizzando la data di rilascio dell'album. Le tracce che presentavano ancora informazioni temporali incomplete sono state escluse.
I valori mancanti per *featured_artists* sono stati estratti dal titolo del brano.
La variabile *language* è stata inizialmente normalizzata nei casi in cui fosse presente ma non standardizzata; nei casi in cui risultasse mancante o non affidabile, è stata inferita automaticamente tramite language detection applicata ai testi delle canzoni.
Le metriche testuali mancanti (*n_tokens*, *n_sentences*, *char_per_tok*, *avg_token_per_clause*) sono state calcolate direttamente sui testi delle canzoni. I valori mancanti corrispondenti all'attributo *explicit* sono stati derivati sulla base della presenza di termini volgari. I valori audio mancanti sono stati imputati utilizzando la mediana delle corrispondenti caratteristiche audio calcolata a livello di singolo artista, sfruttando le informazioni disponibili sulle altre tracce dello stesso artista.

Oltre alla individuazione e trattamento dei valori nulli sono stati creati dei nuovi attributi. Il primo, denominato **geocode**, è stata ottenuta a partire dalle coordinate geografiche presenti nel dataset Artists. Tramite queste informazioni è stato possibile generare un identificatore geografico da associare a ciascun brano.
Dal dataset **Artists** e dal dataset **Tracks** sono stati ricavati i seguenti identificativi. Alcuni sono stati creati ex novo, mentre altri sono stati ridefiniti per garantire coerenza e univocità dei dati:

- *geo_id*: assegnato a ciascun artista sulla base del luogo di nascita. Tale identificativo consente di rappresentare una singola area geografica una sola volta e di collegare più artisti allo stesso contesto territoriale.
- *id_track*: rigenerato combinando l'identificativo dell'artista, la sequenza dell'album e la posizione della traccia all'interno dell'album.
- *album_id*: rigenerato combinando l'identificativo dell'artista e un indice progressivo che rappresenta la sequenza degli album all'interno della discografia dell'artista. In questo modo, tutte le tracce appartenenti allo stesso album condividono lo stesso *album_id*, mentre album diversi dello stesso artista risultano distinti.
- *text_id* e *symp_id*: creati utilizzando la stessa logica gerarchica di *id_track*. Entrambi gli identificativi combinano l'identificativo dell'artista, la sequenza dell'album e la posizione della traccia.
- *date_id*: creato nel formato intero *YYYYMMDD*, ottenuto combinando i campi *year*, *month* e *day*.

1.3 Song profiling

Nel processo di Song Profiling è stato introdotto un nuovo attributo nel dataset finale, denominata **audio_label** , creata per identificare la categoria delle tracce in base alle diverse caratteristiche audio disponibili. Le tracce sono state raggruppate tramite l'algoritmo di clustering k-means, a ciascun cluster individuato è stata successivamente associata un'etichetta descrittiva, definita a posteriori sulla base dei valori medi delle feature audio all'interno di ciascun gruppo. Le etichette assegnate sono: "Standard Urban", "Elettrico & Aggressivo", "Lo-Fi / Chill", "Mainstream Melodico" e "Banger".
Abbiamo anche investigato la possibilità di ottenere categorie musicali dai testi a nostra disposizione. L'obiettivo iniziale era individuare categorie tematiche o stilistiche basate sul contenuto dei testi, così da differenziare i brani oltre le sole informazioni strutturali. In una prima fase abbiamo applicato un modello di clustering testuale sulle liriche delle canzoni, valutando la qualità dei raggruppamenti attraverso il silhouette score. Il risultato ha mostrato silhouette score molto basso, confermando l'assenza di gruppi distinti e suggerendo una scarsa eterogeneità linguistica tra i brani. Abbiamo quindi tentato un approccio alternativo, basato su classificazione a parole chiave: per ogni categoria musicale sono state definite liste di termini rappresentativi e attraverso ricerca lessicale nei testi, i brani venivano assegnati alla categoria corrispondente. Anche questo metodo ha prodotto risultati deboli: i testi presentano una struttura molto simile. Le singole canzoni veniva assegnate a più di una classe. Entrambi gli approcci hanno mostrato un limite comune: il testo, in questo contesto, non fornisce variabilità sufficiente per costruire profili distintivi. Per tale ragione abbiamo riorientato il processo di song profiling solo sulle caratteristiche audio intrinseche dei brani.

1.4 Data Warehouse Schema

Il Data Warehouse è stato progettato per essere funzionale allo studio delle performance di streaming musicale. Lo schema adottato (Figura 1) segue un modello a stella, con la tabella FactSong come elemento centrale. La granularità è stata definita a livello di singola traccia musicale ("id_track"), considerando uno snapshot a un mese dalla data di rilascio. Come misura è stato selezionato l'attributo *streams_1month*, che rappresenta il numero di stream raggiunti da un brano nel primo mese di pubblicazione. Tale metrica è stata scelta in quanto direttamente collegata alle finalità di supporto decisionale del data warehouse ed è completamente additiva rispetto alle dimensioni considerate. L'adozione di uno schema a stella garantisce semplicità strutturale e

prestazioni elevate nelle operazioni di aggregazione, favorendo l'esecuzione di query analitiche frequenti senza introdurre complessità di join superflue.
Lo schema include sei tabelle dimensionali, ciascuna dedicata a descrivere un diverso aspetto dei dati. **DateDim** ci permette di condurre analisi temporali, in particolare grazie agli attributi giorno, mese, anno e stagione. È identificata tramite l'attributo *date_id*, già costruito nella fase di data cleaning a partire dalle informazioni temporali complete della traccia. **ArtistDim**, collegata a **GeographyDim** ci fornisce informazioni relative all'artista e alla relativa provenienza geografica. L'identificativo *geo_id* è stato assegnato nella fase di preparazione dei dati come codice univoco associato al luogo di nascita dell'artista. La dimensione **GeographyDim** utilizza quindi *geo_id* come chiave primaria per associare più artisti allo stesso contesto territoriale. **AlbumDim**, identificata dall'attributo *album_id*, contiene informazioni descrittive dell'album. L'identificativo *album_id* è stato definito in precedenza Nelle tabelle **TextDim** e **SymphonyDim** , identificate rispettivamente da *text_id* e *symp_id*, sono contenute informazioni testuali e melodiche associate alla traccia. Anche in questo caso gli identificativi sono stati assegnati nella fase di data cleaning e successivamente utilizzati per creare le dimensioni, assicurando una corrispondenza univoca alle tracce presenti nella fact table.

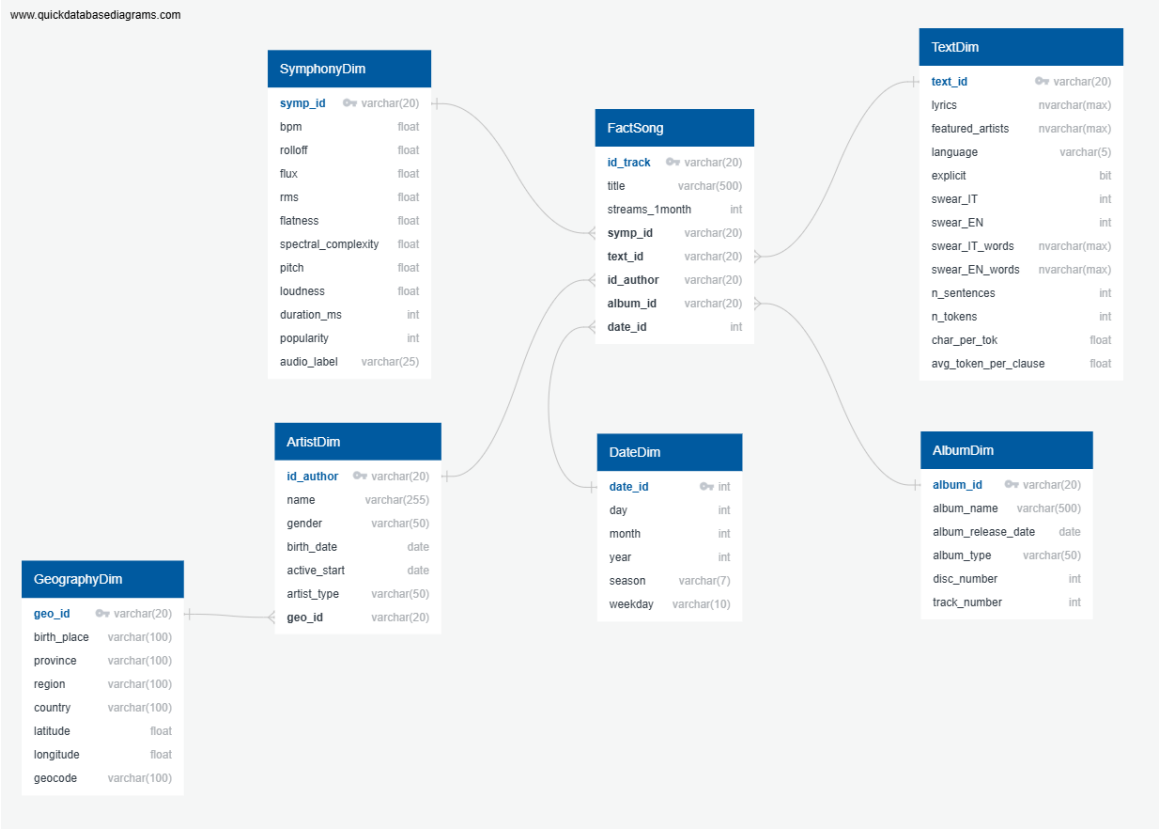


Figure 1: Data Warehouse schema

1.5 Partizionamento dei dati per le tabelle del Data Warehouse

I dati di partenza sono stati suddivisi in più file CSV, uno per ciascuna tabella del Data Warehouse definita nella fase di progettazione. Il partizionamento è stato realizzato tramite un programma Python che, a partire dai dataset originali, estrae per ogni tabella esclusivamente gli attributi necessari, garantendo la coerenza con lo schema logico adottato.
Per la creazione delle tabelle dimensionali è stata implementata una funzione generica che seleziona i record univoci sulla base della chiave primaria, evitando la duplicazione dei dati e assicurando l'unicità delle istanze all'interno di ciascuna dimensione. Questo approccio consente di mantenere una separazione chiara tra dimensioni e fact table, facilitando le successive operazioni di caricamento nel Data Warehouse.

Il risultato di questa fase è un insieme di file di input strutturati e coerenti, pronti per essere utilizzati sia nel caricamento programmatico tramite Python sia nei processi ETL basati su SSIS.

1.6 Data uploading con python

Il caricamento dei dati nel Data Warehouse è stato realizzato in Python tramite la libreria pyodbc. È stata definita una funzione generica per l'inserimento dei dati, utilizzata sia per le tabelle dimensionali sia per la fact table, alla quale vengono forniti il nome della tabella, il file di input e le colonne da popolare.
Prima dell'inserimento, i dati sono sottoposti a una fase di pulizia tecnica finalizzata alla gestione dei valori mancanti e alla normalizzazione dei formati numerici. Durante il caricamento vengono inoltre eseguiti controlli di coerenza sul numero di colonne e verifiche di unicità della chiave primaria, così da prevenire inserimenti duplicati o non conformi allo schema del database.
L'inserimento avviene mediante batch di dimensione prefissata tramite l'operazione executemany, riducendo il numero di chiamate al database e migliorando le prestazioni complessive. Il processo è gestito attraverso commit espliciti al termine di ciascuna fase, consentendo il rollback in caso di errore e garantendo l'integrità dei dati caricati.

1.7 Caricamento dei dati con SSIS (30% del dataset)

Le tabelle originali del Data Warehouse sono state replicate direttamente in SQL Server Management Studio mediante l'esecuzione di una query SQL applicata a ciascuna tabella.
Tale procedura ha consentito di creare tabelle strutturalmente identiche alle originali, ma prive di record, contenenti esclusivamente lo schema.
La duplicazione è stata effettuata utilizzando la seguente query:

```
SELECT *
INTO nome_tabella_SSIS
FROM nome_tabella
WHERE 1 = 0;
```

Per la ripopolazione parziale (30%) delle tabelle duplicate è stata implementata una soluzione in SQL Server Integration Services (SSIS).
Il processo prevede, in una fase iniziale, la cancellazione completa dei record presenti nelle tabelle di destinazione (tabelle SSIS), al fine di garantire la ripetibilità del caricamento ed evitare problemi di duplicazione o inconsistenza dei dati in esecuzioni successive.
Successivamente, è stato applicato un percentage sampling pari al 30% sui dati di origine, consentendo l'estrazione casuale di un sottoinsieme di record. I dati campionati vengono quindi instradati verso distinti OLE DB Source, ciascuno associato a una specifica dimensione.
Per garantire la coerenza referenziale con la fact table, è stata implementata una fase di lookup tra i record delle dimensioni campionate e la fact table campionata al 30%: solo i record per i quali le chiavi risultano coerenti vengono inseriti nelle corrispondenti tabelle SSIS, che vengono così popolate secondo la percentuale richiesta.
Un'eccezione a tale procedura riguarda la GeographyDim, per la quale il lookup non viene effettuato sulla fact table, bensì sulla ArtistDim, in quanto Geography è mediata da quest'ultima e non direttamente dalla fact table.

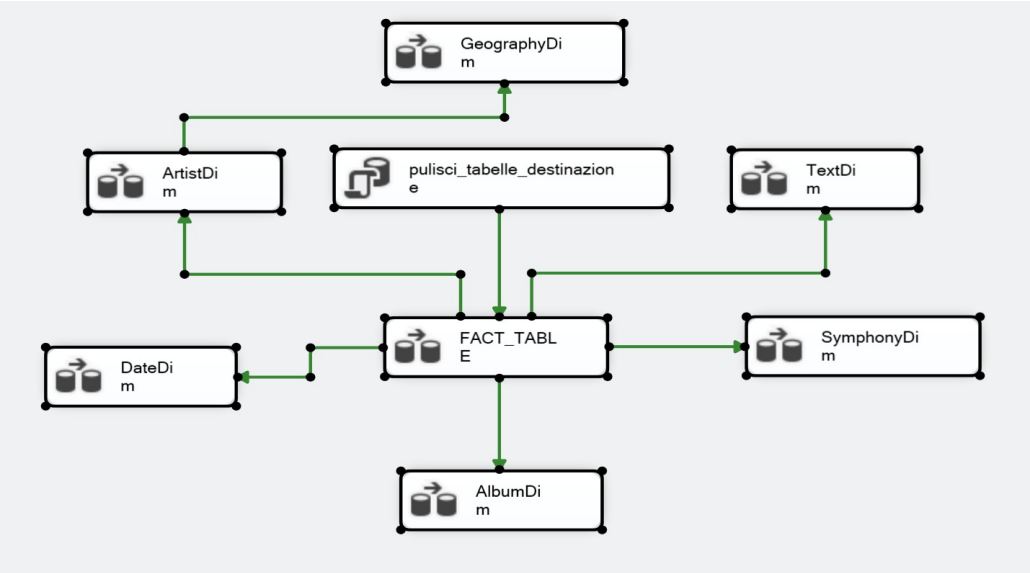


Figure 2: control flow assignment 7

2 Query analitiche con SSIS

2.1 Assignment 8

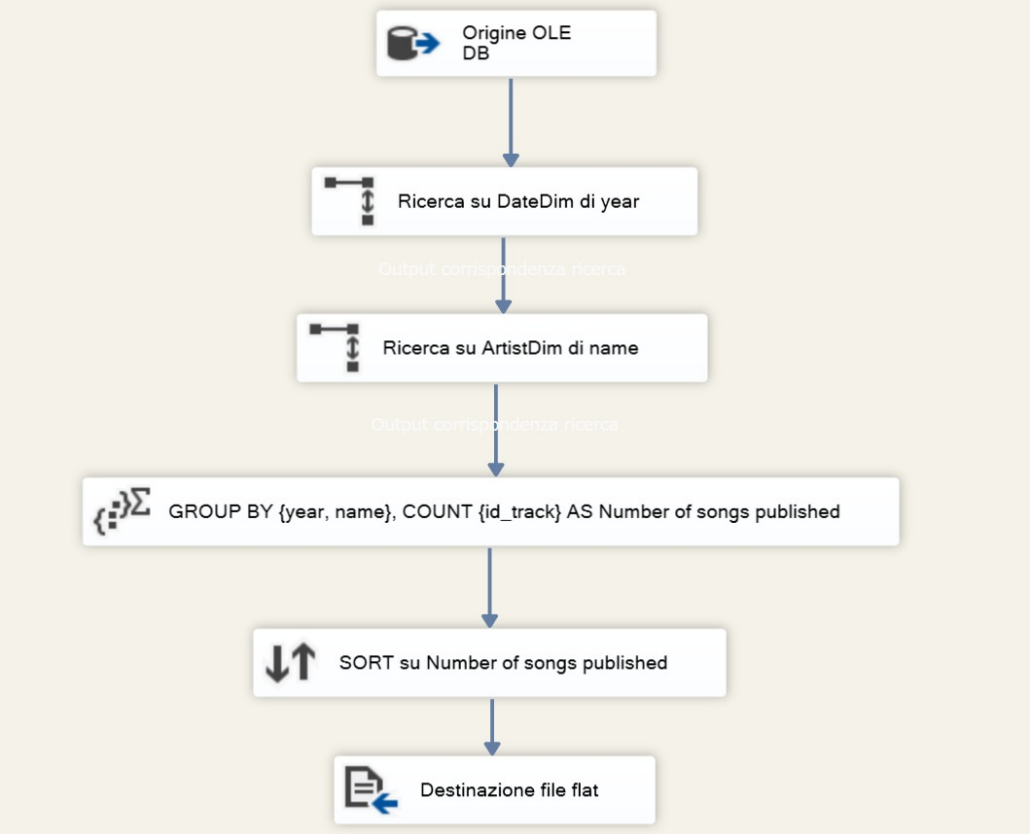


Figure 3: SSIS 8

Per rispondere all'Assignment 8 è stata implementata una query tramite SSIS finalizzata a elencare, per ciascun anno, tutti gli artisti ordinati in base al numero totale di canzoni pubblicate.

2.2 Assignment 9

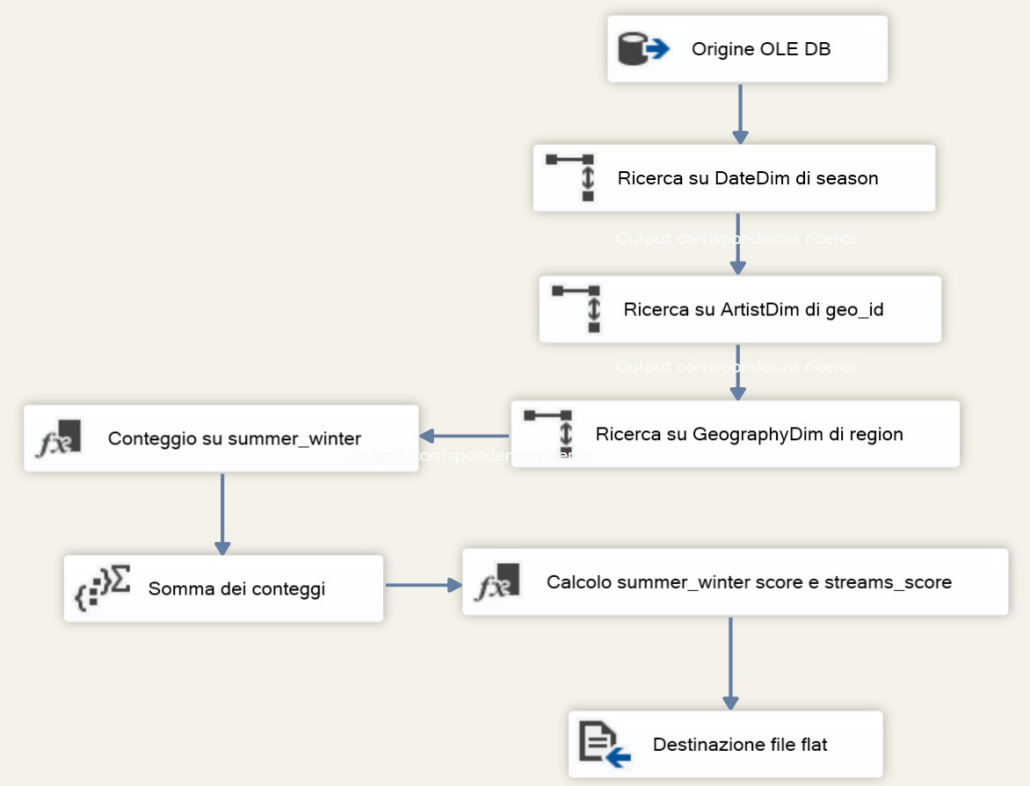


Figure 4: SSIS 9

Per l'Assignment 9, oltre alle operazioni di lookup sulle dimensioni temporali e geografiche, sono state introdotte alcune trasformazioni specifiche per il calcolo degli indicatori richiesti. In particolare, il box Conteggio su summer_winter implementa una logica condizionale che classifica ogni brano in base alla stagione di rilascio, distinguendo tra summer e winter a partire dall'attributo season della DateDim. Tale classificazione consente di contare separatamente il numero di canzoni pubblicate nelle due stagioni senza ricorrere a un multicast e a più aggregazioni distinte, riducendo la duplicazione del flusso di dati e rendendo il processo più efficiente dal punto di vista computazionale. Successivamente, vengono calcolati gli score richiesti dall'assignement: il summer–winter score (definito come il rapporto tra il numero di canzoni pubblicate in estate e quelle pubblicate in inverno) e lo streams score(calcolato analogamente utilizzando il numero di stream a un mese dalla pubblicazione).

2.3 Assignment 10

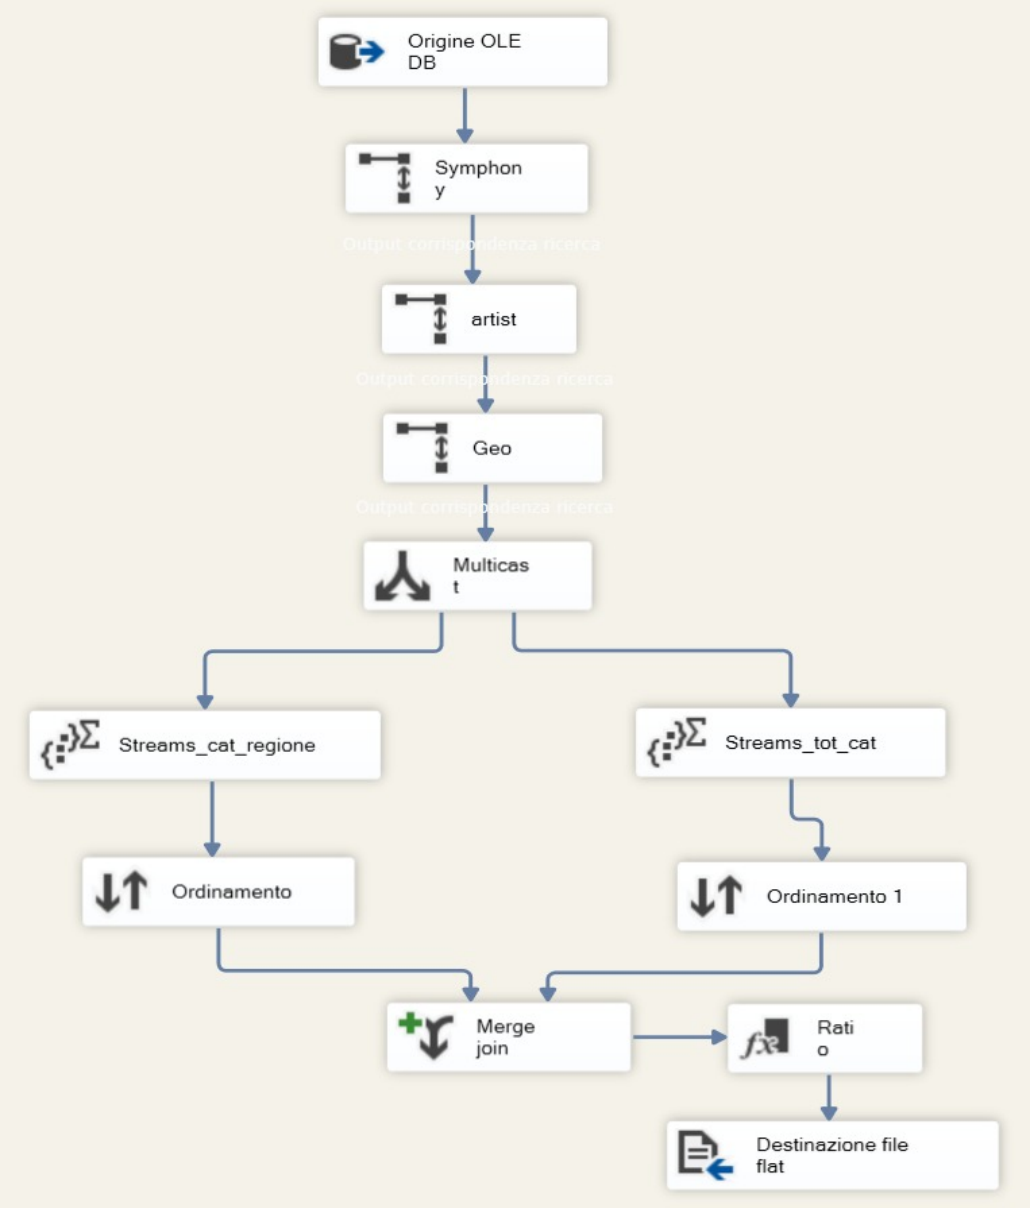


Figure 5: SSIS 10

Per rispondere all'Assignment 10 è stato costruito un flusso SSIS orientato al calcolo di indicatori basati sulla distribuzione degli stream per categoria e area geografica. Durante la fase di integrazione dei dati, i record con valore nullo per l'attributo region sono stati esclusi direttamente nella trasformazione di lookup, così da evitare la propagazione di valori incompleti nelle successive operazioni di aggregazione. Il flusso di dati è stato quindi suddiviso tramite Multicast in due rami distinti: nel primo vengono calcolati gli stream aggregati per categoria e regione, mentre nel secondo vengono calcolati gli stream totali per ciascuna categoria considerando tutte le regioni.

I due risultati aggregati vengono successivamente combinati mediante un'operazione di Merge Join. Nel box finale di calcolo viene determinato il valore del ratio, definito come il rapporto tra gli stream della categoria nella regione considerata e il numero di stream della stessa categoria nelle altre regioni, ottenuto sottraendo al totale di categoria gli stream regionali.

2.4 Assignment 11

Per lo svolgimento dell'Assignment 11 è stato scelto di creare un solo *control flow* per il calcolo delle metriche di *trending factor* e *trending percentage*. Tale scelta è stata motivata dalla volontà di definire un unico flusso di estrazione dei dati, evitando letture ridondanti delle tabelle; inoltre, questa struttura consente di riutilizzare risultati intermedi, come le somme delle canzoni in tendenza, per alimentare contemporaneamente entrambe le metriche.



Figure 6: SSIS 11

Per quanto riguarda il criterio scelto per valutare se una canzone debba essere considerata di tendenza o di flop, sono state utilizzate soglie percentuali fisse (25% in più della media per classificare una traccia come *trending* e 50% in meno della media per considerarla *flopping*). Questa scelta è stata adottata poiché, da un punto di vista di business, risulta più immediato e comprensibile per uno stakeholder affermare che una canzone è in trend quando supera la propria media del 25%. Inoltre, tale approccio è robusto rispetto alla presenza di rumore e outlier, in quanto la soglia rimane sempre legata alla performance media dell'artista: se l'artista cresce gradualmente, la media si adatta di conseguenza, senza essere eccessivamente influenzata da singoli picchi isolati.

Per ottenere risultati più affidabili, sono stati presi in considerazione due *edge case* specifici, per i quali sono state adottate soluzioni dedicate:

- **falso stabile:** categoria di artisti che hanno pubblicato meno di cinque brani, in particolare quelli con un solo brano all'attivo. In questi casi, la media degli stream risulta statisticamente poco affidabile; pertanto, il *trending factor* e il *trending percentage* sono stati calcolati facendo riferimento alla media globale degli stream anziché a quella del singolo artista.
- **hit famosa:** situazione in cui un artista presenta una canzone con un numero di stream significativamente superiore al proprio andamento abituale, tale da spostare verso l'alto la media complessiva e classificare come flop tracce che, in termini assoluti, non dovrebbero esserlo. Per gestire questo caso è stata introdotta una soglia aggiuntiva durante il processo di classificazione: una canzone che supera gli 8000 stream in un mese viene automaticamente considerata di successo, anche se non supera il 25% della media dell'artista.

2.5 Assignment 12



Figure 7: SSIS 12

Per l'Assignment 12 è stata definita una query analitica finalizzata a studiare la relazione tra alcune caratteristiche testuali e musicali dei brani e le loro performance in termini di stream. In particolare, sono stati utilizzati attributi provenienti dalle dimensioni TextDim e SymphonyDim, successivamente combinati con la misura *streams_1month*.
In una prima fase è stato calcolato il rapporto tra il numero di parole volgari e il numero totale di parole del testo, utilizzato per classificare i brani in tre categorie di contenuto esplicito: pulito, con qualche parolaccia e

con molte parolacce. Analogamente, sono state definite tre classi basate sulla lunghezza del testo :breve, medio e lungo. Infine, sono state ottenute tre classi basate sull'attributo *char_per_tok*, impiegato come indicatore della complessità lessicale del brano: lessico basic, lessico standard e lessico ricco.
A queste dimensioni si affianca la classificazione del ritmo, derivata dagli attributi musicali.
Una volta definite le classi, i brani sono stati aggregati tramite un'operazione di group by sulle categorie di contenuto esplicito, ritmo, lessico e struttura del testo. Per ciascuna combinazione sono stati calcolati la media degli stream ad un mese dalla pubblicazione e il numero di tracce. Consentendo di analizzare quali combinazioni di caratteristiche risultano associate a performance migliori.

2.6 Assignment 13

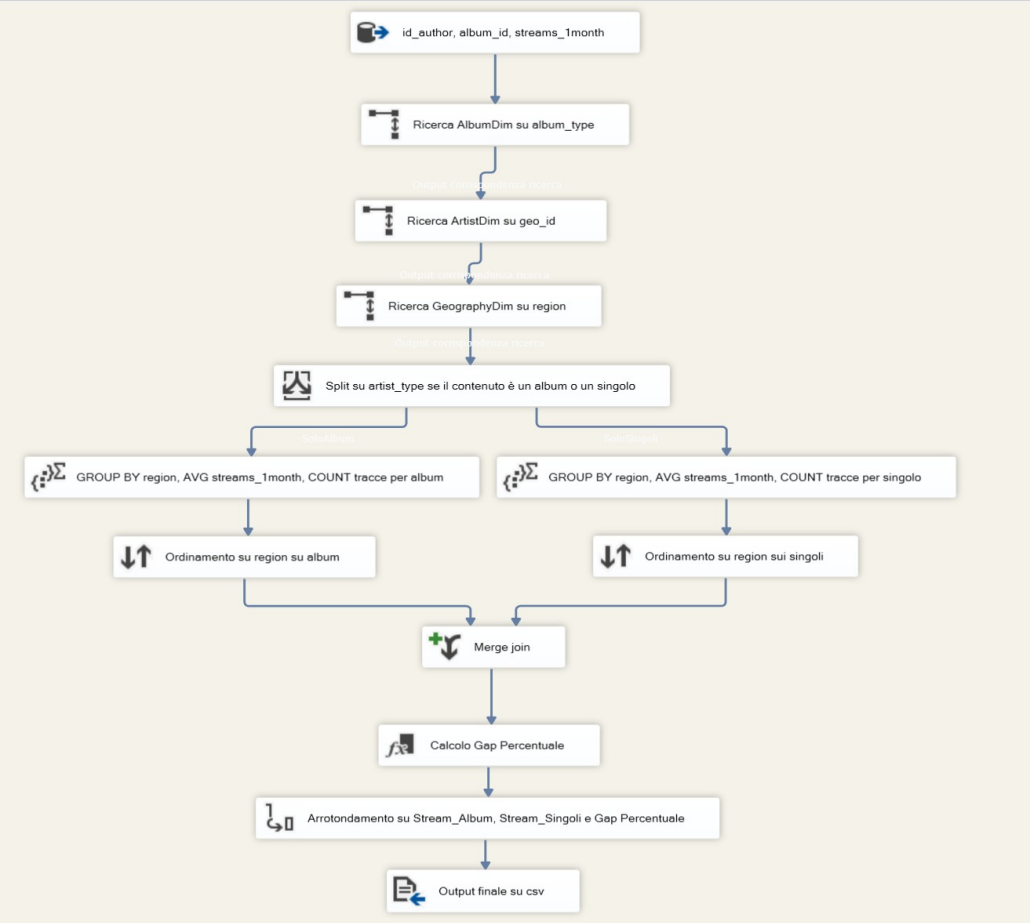


Figure 8: SSIS 11

La query proposta mira a confrontare le performance di streaming di album e singoli nelle diverse regioni, analizzando eventuali differenze significative in termini di numero medio di stream. Questo tipo di analisi risulta rilevante per una casa discografica in quanto consente di valutare se, e in quali aree geografiche, la pubblicazione di singoli risulti più efficace rispetto alla distribuzione di album completi, supportando scelte strategiche di marketing e pianificazione delle uscite.
Il flusso parte dall'estrazione delle informazioni sugli artisti, sugli album e sul numero di stream a un mese dalla pubblicazione, successivamente arricchite tramite operazioni di lookup sulle dimensioni AlbumDim, ArtistDim e GeographyDim.I dati vengono quindi separati in due rami distinti attraverso uno split basato sul tipo di contenuto, distinguendo tra brani appartenenti ad album e singoli. Per ciascun ramo vengono calcolati, tramite aggregazione, il numero medio di stream e il numero di tracce per regione. I risultati ottenuti vengono successivamente riordinati e combinati mediante un'operazione di Merge Join. Nella fase finale del flusso viene calcolato

il gap percentuale tra le performance medie di album e singoli, al fine di evidenziare eventuali differenze significative a livello regionale.

3 Multidimensional Data Analysis

3.1 OLAP Cube

Per la creazione del data cube multidimensionale è stata creata una soluzione **analysis services multidimensional and data mining**, su Visual Studio, nella quale sono state fatte le seguenti oeperazioni:

1. Connessione al nostro DW Group_ID_6 come data source
2. Creazione di una view per definire le relazioni fra tabelle
3. Creazione delle dimensioni, in particolare è stata fatta una selezione degli attributi per ogni tabella (anche in vista delle query in **mdx** richieste fatta eccezione per AlbumDim che è stata scartata totalmente perchè guidicata non utile allo scopo
4. Definizione delle gerarchie per la dimensione temporale (DateDim) e per la dimensione geografica (GeographyDim)
5. Creazione e successivo deploy del cubo multidimensionale su SSMS in modo per poter effettuare query in mdx

L'unica misura inclusa nel cubo è il numero di stream ad un mese dall'uscita del brano.

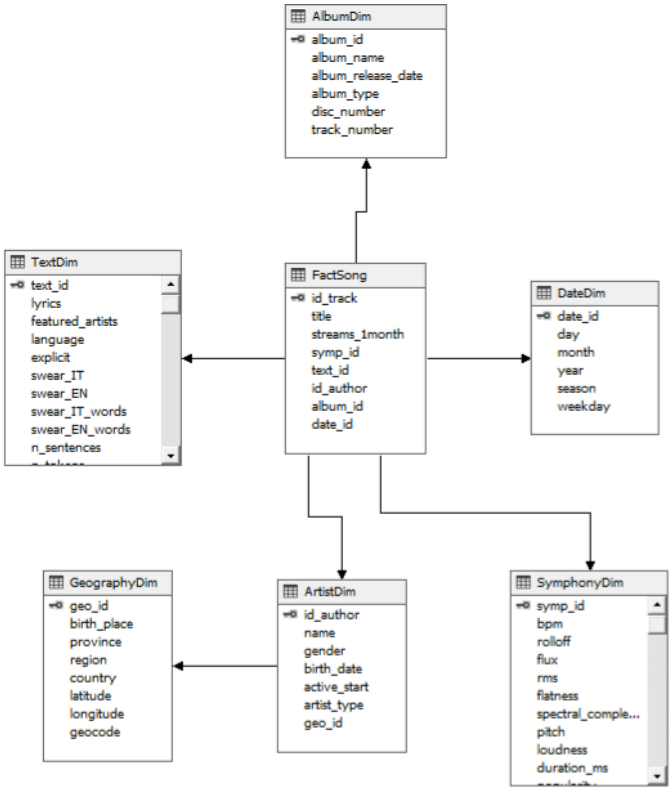


Figure 9: vista del data cube in Visual Studio

3.2 MDX queries

3.2.1 Assignment 15

```
SELECT
```

```
    NON EMPTY {
        EXCEPT(
            [Date Dim].[Year].[Year].Members,
            { [Date Dim].[Year].[Unknown] }
        )
        *
        {
            [Date Dim].[Month].[Month].Members,
            [Date Dim].[Month].[All]
        }
    } ON COLUMNS,

    NON EMPTY {

        FILTER(
            [Geography Dim].[Region].Children,
            Len([Geography Dim].[Region].CurrentMember.Name) > 0
        ),

        { [Geography Dim].[Region].[All] }

    } ON ROWS

FROM [Group ID 6 DB]
WHERE ( [Measures].[Streams 1month] )
```

3.2.2 Assignment 16

```
WITH
MEMBER [Measures].[Score Main] AS
    [Measures].[Streams 1month] * 0.8

MEMBER [Measures].[Score Featured] AS
    SUM(
        FILTER(
            NONEMPTY(
                [Text Dim].[Featured Artists].Members,
                ( [Measures].[Streams 1month], [Artist Dim].[Name].[All] )
            ),
            InStr(
                1,
                [Text Dim].[Featured Artists].CurrentMember.Name,
                CASE
                    WHEN InStr(1, [Artist Dim].[Name].CurrentMember.Name, "guè pequeno", 1) > 0 THEN "Guè"
                    WHEN InStr(1, [Artist Dim].[Name].CurrentMember.Name, "anna pepe", 1) > 0 THEN "Anna"
                    WHEN InStr(1, [Artist Dim].[Name].CurrentMember.Name, "chadia rodriguez", 1) > 0 THEN "Chadia"
                    WHEN InStr(1, [Artist Dim].[Name].CurrentMember.Name, "samuel heron", 1) > 0 THEN "Samuel"
                    ELSE [Artist Dim].[Name].CurrentMember.Name
                END,
                1
            ) > 0
        ),
        ( [Measures].[Streams 1month], [Artist Dim].[Name].[All] )
    ) * 0.2

MEMBER [Measures].[Total Year Streams] AS
    (
        [Measures].[Streams 1month],
        [Artist Dim].[Name].[All],
        [Text Dim].[Featured Artists].[All]
    )
```

```
MEMBER [Measures].[Avg Yearly Artist Streams] AS
    DIVIDE(
        ( [Measures].[Score Main] + [Measures].[Score Featured] ),
        [Measures].[Total Year Streams]
    ),
    FORMAT_STRING = 'Percent'

SELECT
    NON EMPTY { [Date Dim].[Year].[Year].Members } ON COLUMNS,
    NON EMPTY { [Artist Dim].[Name].[Name].Members } ON ROWS
FROM [Group ID 6 DB]
WHERE ( [Measures].[Avg Yearly Artist Streams] )
```

Per garantire una corretta attribuzione dei volumi di ascolto per gli artisti che compaiono nelle collaborazioni, è stata implementata una procedura di validazione volta a identificare gli *alias* degli artisti che non combaciassero. Successivamente è stata gestita su mdx, al fine di ottenere una metrica di *stream ponderati* e offrire una visione accurata sull'influenza di quell'artista nel mercato.

3.2.3 Assignment 17

```
WITH
    -- 1. Recuperiamo gli Stream dell'Anno Precedente
    MEMBER [Measures].[Streams Prev Year] AS
    (
        [Measures].[Streams 1month],
        [Date Dim].[Year].CurrentMember.PrevMember
    )

    -- 2. Calcoliamo la variazione percentuale (Growth)
    MEMBER [Measures].[YoY Growth] AS
    DIVIDE(
        ([Measures].[Streams 1month] - [Measures].[Streams Prev Year]),
        [Measures].[Streams Prev Year]
    ), FORMAT_STRING = "Percent"

SELECT
    -- COLONNE: Anni
    NON EMPTY {
        EXCEPT(
            [Date Dim].[Year].[Year].Members,
            { [Date Dim].[Year].[Unknown] }
        )
    } ON COLUMNS,

    -- RIGHE: Le Categorie
    NON EMPTY {
        [Symphony Dim].[Audio Label].[Audio Label].Members
    } ON ROWS

FROM [Group ID 6 DB]
WHERE ( [Measures].[YoY Growth] )
```

L'analisi ha evidenziati tassi di crescita percentuale anomali, concentrati per la maggior parte nei primi anni di osservazione. Questa distorsione fa si che un numero di ascolti trascurabile nell'anno precedente generi percentuali esponenziali, amplificate se nell'anno successivo viene rilevata una canzone che in quel profilo ha riscosso successo. Pertanto è necessaria una contestualizzazione per distinguere l'effettiva esplosione di un trend dal mero rumore statistico.

3.2.4 Assignment 18

```
WITH
MEMBER [Measures].[Avg Prev Season] AS
    AVG(
        DESCENDANTS(
            ParallelPeriod(
                [Date Dim].[Year].[Year],
                1,
                [Date Dim].[Year].CurrentMember
            ),
            [Date Dim].[Month]
        ),
        [Measures].[Streams 1month]
    )

MEMBER [Measures].[Season Increase Percentage] AS
    IIF(
        ISEMPTY([Measures].[Avg Prev Season])
        OR [Measures].[Avg Prev Season] = 0,
        NULL,
        (
            [Measures].[Streams 1month]
            - [Measures].[Avg Prev Season]
        )
        / [Measures].[Avg Prev Season]
    ),
    FORMAT_STRING = "0.00%"

SELECT
{
    [Measures].[Streams 1month],
    [Measures].[Avg Prev Season],
    [Measures].[Season Increase Percentage]
} ON COLUMNS,

NON EMPTY
FILTER(
    [Symphony Dim].[Audio Label].[Audio Label].Members
    *
    [Date Dim].[Season].[Season].Members,
    [Measures].[Streams 1month] > [Measures].[Avg Prev Season]
) ON ROWS

FROM [Group ID 6 DB]
```

L'elaborazione confronta i flussi mensili della stagione corrente con la media della stessa stagione nell'anno precedente, evidenziando esclusivamente i casi di crescita positiva. Tuttavia, in presenza di volumi storici ridotti, anche variazioni assolute contenute possono tradursi in incrementi percentuali elevati, rendendo necessaria una lettura cauta del risultato.

3.2.5 Relative popularity index

Questa analisi, implementata tramite una query MDX, mira a determinare il grado di specializzazione dei consumi musicali regionali rispetto al benchmark nazionale. L'indice calcolato confronta la quota di mercato locale di un determinato genere con la sua incidenza media sul totale degli ascolti nazionali.

```
MEMBER [Measures].[Calc_Region_Share] AS
```

```
    DIVIDE(
        [Measures].[Streams 1month],
        ([Measures].[Streams 1month], [Symphony Dim].[Audio Label].[All]),
        0
    ), FORMAT_STRING = "Percent"

MEMBER [Measures].[Calc_Global_Share] AS
    DIVIDE(
        ([Measures].[Streams 1month], [Geography Dim].[Hierarchy].[All]),
        ([Measures].[Streams 1month], [Geography Dim].[Hierarchy].[All], [Symphony Dim].[Audio Label].[All]),
        0
    ), FORMAT_STRING = "Percent"

MEMBER [Measures].[Calc_Penetration_Index] AS
    IIF(
        [Measures].[Calc_Global_Share] = 0,
        0,
        [Measures].[Calc_Region_Share] / [Measures].[Calc_Global_Share]
    ), FORMAT_STRING = "0.00"

SELECT
{
    [Measures].[Calc_Region_Share],
    [Measures].[Calc_Global_Share],
    [Measures].[Calc_Penetration_Index]
} ON COLUMNS,
NON EMPTY
(
    [Geography Dim].[Hierarchy].[Region].Members
    * [Symphony Dim].[Audio Label].[Audio Label].Members
) ON ROWS
FROM [Group ID 6 DB]
```

Un valore di Relative Popularity Index superiore a 1.00 indica un'anomalia positiva: in quella specifica area, il genere è più rilevante rispetto alla media del Paese. I risultati mostrano evidenze empiriche di forti cluster culturali territoriali:

- Il genere **"Mainstream Melodico"** in **Calabria** registra un indice di **2.80**, indicando una penetrazione quasi tripla rispetto alla media.
- Il genere **"Lo-fi/Chill"** in **Toscana** raggiunge un valore di **2.09**, evidenziando una predilezione regionale per sonorità atmosferiche.

Business Insight: Dal punto di vista strategico, l'RPI funge da indicatore di *Market Attractiveness*. Questi dati consentono alle etichette discografiche e ai promoter di ottimizzare l'allocazione del budget pubblicitario e di pianificare tour live con un rischio d'impresa ridotto, concentrando le risorse dove la domanda organica è statisticamente più alta e la fedeltà al genere è già consolidata.

4 Dashboards

4.1 Distribuzione degli stream per luogo di nascita dell'artista e categoria del brano

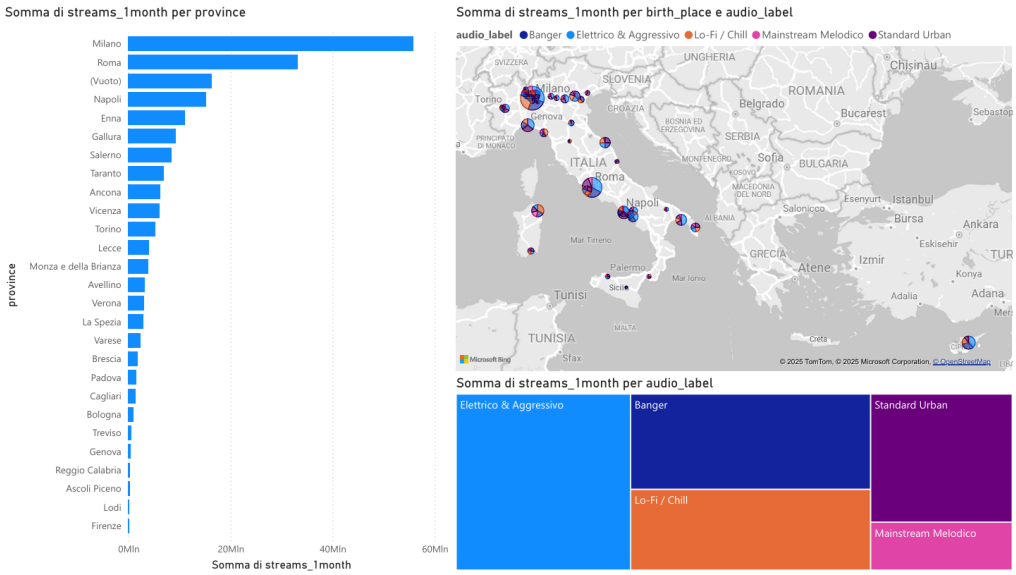


Figure 10: Assignment 20

Questa dashboard è stata progettata con l'obiettivo di analizzare l'evoluzione temporale del consumo musicale, mettendo in relazione il volume degli stream con le categorie audio e la tipologia di artista.
La **Line Chart** rappresenta la scelta principale per visualizzare l'andamento degli stream nel tempo, in quanto consente di cogliere chiaramente le dinamiche di crescita e di declino delle diverse audio label nel corso degli anni. L'utilizzo di linee multiple permette un confronto diretto tra le categorie musicali, evidenziando come alcune di esse, in particolare Banger ed Elettrico & Aggressivo, abbiano conosciuto una crescita molto più marcata a partire dalla metà degli anni 2010. Questa visualizzazione risulta particolarmente efficace nel mettere in luce sia i picchi di popolarità sia i cambiamenti strutturali del mercato musicale.
Per arricchire l'analisi, è stata affiancata una **Stacked Bar Chart** che mostra il conteggio delle audio label per anno. Questa scelta consente di osservare l'evoluzione della produzione musicale nel tempo, fornendo un'indicazione sul numero di tracce pubblicate per ciascun periodo e permettendo di interpretare i trend degli stream anche in funzione della quantità di contenuti disponibili.
La **Donut Chart** dedicata alla tipologia di artista (solista vs gruppo) è stata introdotta per offrire una sintesi immediata della distribuzione degli stream tra le due categorie. La predominanza dei solisti emerge chiaramente, suggerendo una maggiore concentrazione del successo commerciale su artisti individuali rispetto ai gruppi musicali.
Infine, la **Treemap** consente di confrontare il peso complessivo delle diverse audio label in termini di stream totali. Questa visualizzazione è particolarmente adatta a rappresentare proporzioni e gerarchie, evidenziando in modo intuitivo le categorie musicali dominanti all'interno del dataset.
Nel complesso, la combinazione di queste visualizzazioni permette di analizzare il fenomeno degli stream musicali da più prospettive (temporale, categoriale e strutturale) offrendo una lettura completa e coerente delle dinamiche che caratterizzano l'evoluzione del mercato musicale sulle piattaforme di streaming.

4.2 Lyrics analysis

L'analisi della complessità testuale tramite **Line Chart** rivela che la lunghezza media dei testi non segue un trend di crescita lineare, ed evidenzia invece una forte volatilità nel corso degli anni. Un insight particolarmente rilevante emerge effettuando il drill-down sull'attributo temporale mensile: mentre la produzione dei solisti mantiene una lunghezza testuale estremamente costante e prevedibile, i gruppi musicali mostrano una varianza molto più elevata. Questa discrepanza suggerisce che le dinamiche creative dei gruppi siano meno standardizzate, probabilmente influenzate dal numero di collaboratori o dalla natura episodica dei progetti collettivi rispetto alla regolarità dei singoli artisti.

Per la seconda visualizzazione è stata scelta una **Stacked Area Chart** per analizzare il volume di stream in funzione della natura del testo (Explicit vs Clean) nel corso degli anni. Il grafico evidenzia non solo che le canzoni con linguaggio esplicito generano un volume di vendite superiore, ma rivela un netto cambiamento strutturale del mercato: se fino al 2010 la quota di stream tra contenuti espliciti e non era bilanciata, nell'ultimo decennio si assiste a una quasi totale egemonia dei brani 'Explicit'. Questo trend, in costante crescita, suggerisce che l'esplicitezza linguistica sia diventata una caratteristica intrinseca dei generi dominanti presenti nelle piattaforme di streaming , influenzando direttamente le performance commerciali.

Le ultime due visualizzazioni sono realizzate tramite **Stacked Bar Chart**. La prima analizza la propensione degli artisti all'uso di un linguaggio esplicito, distinguendo tra imprecazioni in lingua italiana e inglese. Emerge chiaramente una forte tendenza all'internazionalizzazione del linguaggio: per diversi artisti, l'uso di termini espliciti stranieri supera quello locale, riflettendo le influenze d'oltreoceano del genere. Parallelamente, il secondo grafico segmenta le tracce esplicite per genere musicale, evidenziando come i brani classificati come 'Banger' e 'Lo-Fi / Chill' siano i più espliciti del dataset. Questo incrocio di dati suggerisce che l'esplicitezza non sia limitata a generi aggressivi, ma sia ormai una componente pervasiva anche in sonorità più rilassate, consolidando un modello comunicativo comune a tutta la scena musicale moderna.

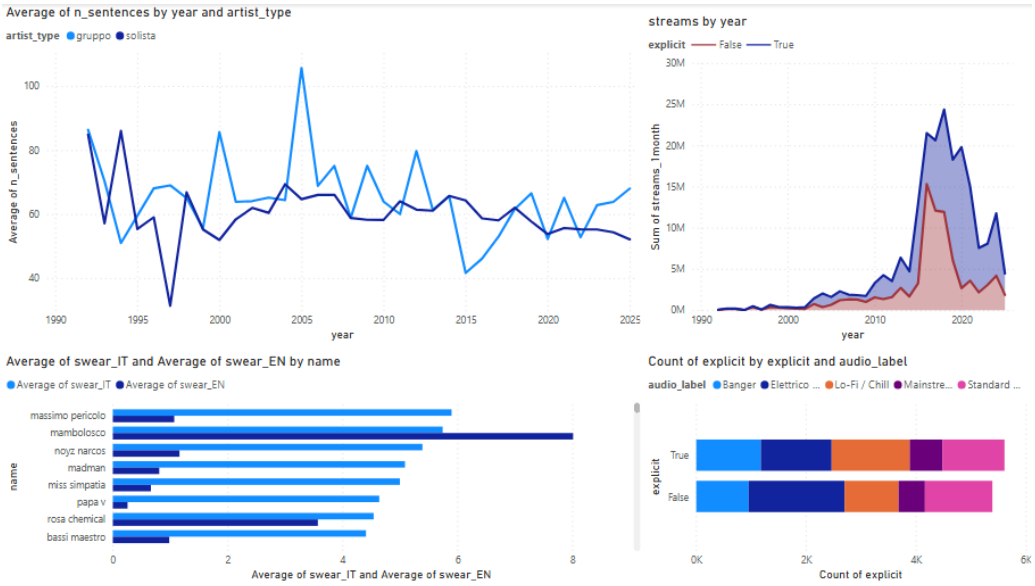


Figure 11: Assignment 21

4.3 Evoluzione temporale degli stream e delle categorie musicali

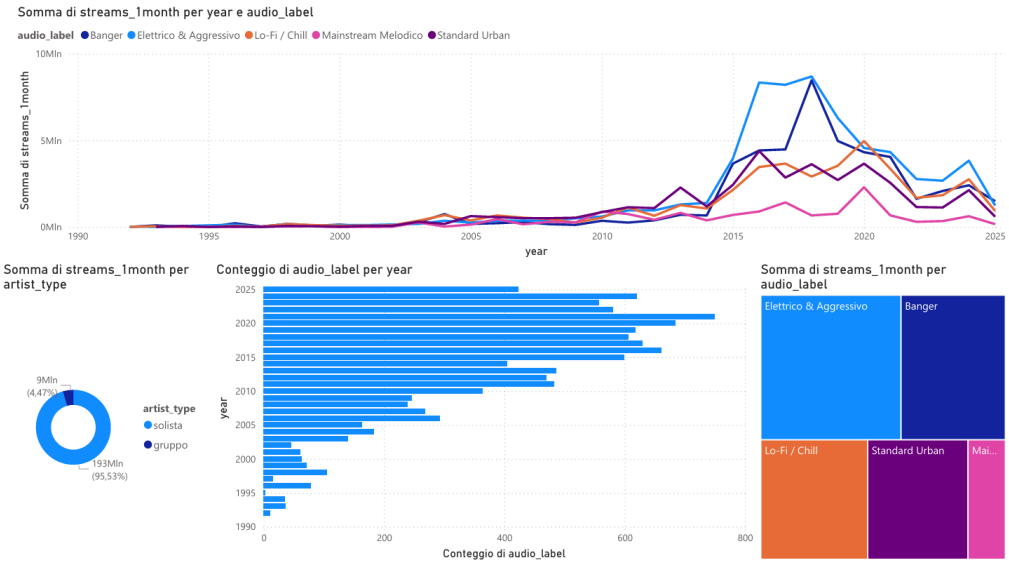


Figure 12: Assignment 22

Questa dashboard è stata progettata con l'obiettivo di analizzare l'evoluzione temporale del consumo musicale, mettendo in relazione il volume degli stream con le categorie audio e la tipologia di artista.
La **Line Chart** rappresenta la scelta principale per visualizzare l'andamento degli stream nel tempo, in quanto consente di cogliere chiaramente le dinamiche di crescita e di declino delle diverse audio label nel corso degli anni. L'utilizzo di linee multiple permette un confronto diretto tra le categorie musicali, evidenziando come alcune di esse, in particolare Banger ed Elettrico & Aggressivo, abbiano conosciuto una crescita molto più marcata a partire dalla metà degli anni 2010. Questa visualizzazione risulta particolarmente efficace nel mettere in luce sia i picchi di popolarità sia i cambiamenti strutturali del mercato musicale.
Per arricchire l'analisi, è stata affiancata una **Stacked Bar Chart** che mostra il conteggio delle audio label per anno. Questa scelta consente di osservare l'evoluzione della produzione musicale nel tempo, fornendo un'indicazione sul numero di tracce pubblicate per ciascun periodo e permettendo di interpretare i trend degli stream anche in funzione della quantità di contenuti disponibili.
La **Donut Chart** dedicata alla tipologia di artista (solista vs gruppo) è stata introdotta per offrire una sintesi immediata della distribuzione degli stream tra le due categorie. La predominanza dei solisti emerge chiaramente, suggerendo una maggiore concentrazione del successo commerciale su artisti individuali rispetto ai gruppi musicali.
Infine, la **Treemap** consente di confrontare il peso complessivo delle diverse audio label in termini di stream totali. Questa visualizzazione è particolarmente adatta a rappresentare proporzioni e gerarchie, evidenziando in modo intuitivo le categorie musicali dominanti all'interno del dataset.
Nel complesso, la combinazione di queste visualizzazioni permette di analizzare il fenomeno degli stream musicali da più prospettive (temporale, categoriale e strutturale) offrendo una lettura completa e coerente delle dinamiche che caratterizzano l'evoluzione del mercato musicale sulle piattaforme di streaming.